



Projet 4IM01

Images 3D et 3D+t : segmentation d'IRM du cœur

Réalisé Par :

- FATNASSI Rayan
- BEN EL GHALI Amir Loris

Encadré par :

- M. LE FOLGOC Loïc

Année universitaire
2024/2025

Table de Matière

INTRODUCTION	4
1. PIPELINE DU PROJET	5
2. BASE DE DONNEES ET MANIPULATION	6
2.1 PRESENTATION DE LA BASE DE DONNEES :	6
2.2 CARACTERISTIQUES DES IMAGES IRM	6
3. DETECTION DU POINT INITIAL PAR LA METHODE DE HOUGH CERCLE	8
3.1 THEORIE	8
3.2 IMPLEMENTATION.....	11
3.3 ENTRAINEMENT, AMELIORATION ET RECHERCHE DES PARAMETRES OPTIMAUX	13
3.4 RESULTATS ET DISCUSSION	15
3.5 CONCLUSION DES RESULTATS	18
4. SEGMENTATION DU VENTRICULE GAUCHE PAR CROISSANCE REGIONALE	19
4.1 THEORIE (REGION GROWING).....	19
4.2 EXPERIENCE ET AMELIORATION	21
4.3 RESULTATS ET DISCUSSION	24
4.4 CONCLUSION	27
5. PROPAGATION SPATIO-TEMPORELLE.....	28
5.1 THEORIE	28
5.2 IMPLEMENTATION (PROPAGATION SPATIALE) :	29
5.3 RESULTATS DE LA PROPAGATION SPATIALE	30
5.4 PROPAGATION TEMPORELLE	32
6. VERS UNE OUVERTURE : APPROCHES BASEES SUR LE DEEP LEARNING	35
6.1 UNE DECOUVERTE BASEE SUR LA RECHERCHE.....	35
CONCLUSION	37
REFERENCES	38

Table de figures

FIGURE 1-1 CHEMIN DE BLOC POUR LE PIPELINE DU PROJET	5
FIGURE 2-1 FICHIER INFO POUR UN PATIENT EXEMPLE	7
FIGURE 2-2 EXEMPLE DE VERITE TERRAIN.....	7
FIGURE 3-1 TRANSFORMATION PARAMETRIQUE	9
FIGURE 3-2 PHOTO DE DIFFERENCE ENTRE SYSTOLE ET DIASTOLE	9
FIGURE 3-3 PHOTO DE LA PREMIERE HARMONIQUE NON NULLE	10
FIGURE 3-4 ILLUSTRATION DU SUCCES DE DETECTION DU POINT INITIALE	16
FIGURE 3-5 ILLUSTRATION D'ECHEC POUR PATIENTS 10 , 11 ,34 47	17
FIGURE 3-6 ILLUSTRATION D'ECHEC POUR PATIENTS 6, 14, 33.....	17
FIGURE 4-1 CHEMIN DE BLOC DE VARIATION DE SEUIL	20
FIGURE 4-2 AVANT ET APRES APPLICATION DU FILTRE MEDIAN.....	21
FIGURE 4-3 AVANT ET APRES FERMETURE	22
FIGURE 4-4 VISUALISATION DU SUCCES DE LA PREMIER SEGMENTATION.....	25
FIGURE 4-5 MAUVAISE SEGMENTATION POUR LE PATIENT 16 ET 26.....	26
FIGURE 4-6 SURSUGMENTATION POUR PATIENT 13 ET E1	26
FIGURE 5-1 PROPAGATION DE LA SEGMENTATION POUR LE PATIENT 7	30
FIGURE 5-2PROPAGATION DE LA SEGMENTATION POUR LE PATIENT 9.....	31
FIGURE 5-3PROPAGATION DE LA SEGMENTATION POUR LE PATIENT 49.....	31
FIGURE 5-4 PROPAGATION SPATIO-TEMPORELLE.....	34

Introduction

La segmentation du ventricule gauche dans les images d'IRM cardiaque est un domaine clé en imagerie médicale, avec des applications majeures dans le diagnostic, le suivi des pathologies cardiaques, et la planification des interventions. Cette tâche est d'autant plus cruciale lorsqu'elle est étendue à la dimension temporelle, permettant d'analyser les variations fonctionnelles du cœur au cours du cycle cardiaque. Cependant, la segmentation manuelle reste une procédure longue, sujette à des variations inter-observateurs, et peu adaptée à des volumes de données toujours plus importants. D'où l'importance de développer des approches automatisées fiables et robustes pour ce processus complexe.

Dans le cadre du projet 4IM01, nous avons mis en œuvre une méthode inspirée de l'article scientifique «*Automatic Left Ventricle Segmentation Using Iterative Thresholding and an Active Contour Model With Adaptation on Short-Axis Cardiac MRI* [1]», qui repose sur une combinaison d'approches de détection et de segmentation adaptées spécifiquement à la géométrie et à la dynamique du ventricule gauche. Le processus développé pour la segmentation 3D+t du ventricule gauche suit une structure en plusieurs étapes clés : **Détection initiale des points d'intérêt** (Point initiale pour la segmentation), **Segmentation par croissance de région** (region growing) et finalement **Propagation spatio-temporelle**.

Cependant, tout au long du projet, nous avons rencontré plusieurs défis, notamment liés à la variabilité des conditions d'acquisition des IRM ou à la complexité des formes anatomiques ainsi que la sensibilité de la méthode au paramètre. Ces obstacles ont nécessité l'ajout de modifications et d'améliorations méthodologiques. Des ajustements ont été apportés à chaque étape du processus pour renforcer la précision et la robustesse de notre approche, en s'appuyant sur une validation expérimentale rigoureuse.

Ce rapport détaille le développement, l'implémentation, et l'évaluation de notre méthodologie, en mettant en lumière non seulement les **avancées réalisées**, mais aussi **les défis surmontés**, **les limitations de notre implémentation** ainsi que **les perspectives ouvertes** par ce travail.

1. Pipeline du Projet

La méthodologie développée dans notre projet suit un pipeline structuré (inspire de l'article) en plusieurs étapes, chacune jouant un rôle essentiel dans la segmentation automatique et spatio-temporelle du ventricule gauche. Ce pipeline repose sur des principes éprouvés tout en intégrant des améliorations adaptées aux besoins spécifiques des données et des résultats attendus :

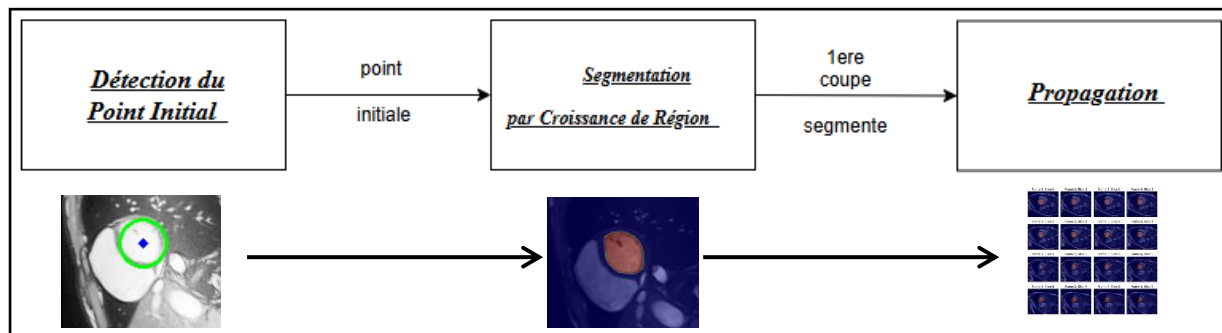


Figure 1-1 Chemin de bloc pour le pipeline du projet

Etape 1 : Détection du Point Initial

La première étape consiste à détecter le point initial pour la segmentation. Le ventricule gauche, de par sa forme approximativement circulaire, se prête bien à une détection par la méthode de Hough Cercle. Cet algorithme identifie les cercles présents dans les images (dans une coupe où le ventricule gauche est **le plus visible et l'instant le plus visible c'est-à-dire la diastole** d'ailleurs le choix de cette coupe va être justifié ultérieurement), permettant ainsi de repérer avec précision le ventricule gauche et son centre. Ce centre constitue un point de départ essentiel pour les étapes suivantes, car il fournit une **position initiale** pour initier la segmentation par croissance de région.

Etape 2 : Segmentation par Croissance de Région

Une fois le point initial identifié, la segmentation du ventricule gauche commence par un algorithme de **region growing**. Dans cette étape, un seuil est ajusté progressivement, croissant ou décroissant, pour déterminer les pixels appartenant à la région du ventricule gauche. La croissance s'arrête dès que l'on détecte une discontinuité significative (appelée "explosion de volume"), qui indique un débordement hors des limites anatomiques du ventricule gauche. Cette segmentation permet de définir une région cohérente et précise, à partir de laquelle des paramètres clés, tels que **le centre de gravité** et **l'intensité moyenne** du ventricule gauche segmenté, sont calculés pour la phase suivante.

Etape 3 : Propagation

La segmentation obtenue dans une coupe initiale est ensuite propagée aux autres coupes anatomiques et aux différents instants temporels. Cette étape utilise une technique de propagation des points de départ (**seed propagation**), basée sur l'analyse d'une fenêtre de 11×11 pixels centrée sur **le centre de gravité** du ventricule segmenté dans l'image précédente. Chaque pixel dans cette fenêtre est évalué en fonction de son énergie, calculée à partir de deux facteurs : **la distance par rapport au centre de la fenêtre** et **la différence d'intensité par rapport** à la moyenne du ventricule segmenté dans l'image précédente.

2. Base de données et manipulation

2.1 Présentation de la base de données :

Dans le cadre de ce projet, nous avons utilisé la base de données « **Automate Cardiac Diagnosis Challenge (ACDC)** [2] », spécialement conçue pour les études et analyses sur le cœur. Cette base de données est structurée en deux parties principales :

- Jeu d'entraînement (train) (100 patients)
- Jeu de test (test) (50 patients)

Chaque partie est composée de dossiers correspondant à des patients, et chaque dossier patient contient les éléments suivants :

a) *Un fichier informatif* : Ce fichier fournit des informations essentielles telles que :

- Les indices des frames correspondant à la diastole et à la systole.
- Le nombre total de frames disponibles.
- La pathologie du patient.
- La taille et le poids du patient.

b) *Un dossier compressé contenant les images IRM* : Ce dossier regroupe toutes les images ciné-MRI du cœur du patient.

c) *Deux dossiers compressés pour les masques de vérité terrain*

Ces masques représentent la segmentation des structures cardiaques clés aux deux instants critiques (diastole et systole) :

- Myocarde (codé 1)
- Ventricule droit (codé 2)
- Ventricule gauche (codé 3)
- Les pixels en dehors de ces structures sont codés 0.

Les masques sont définis donc sur une échelle $\llbracket 0,3 \rrbracket$.

2.2 Caractéristiques des Images IRM

Chaque image IRM est représentée sous forme d'un tableau à quatre dimensions de la forme $[nf, N, M, ns]$, où :

- nf : Nombre de frames dans la séquence temporelle.
- N : Hauteur de l'image.
- M : Largeur de l'image.
- ns : Nombre de coupes spatiales de l'image.

2.2.1 Manipulation et Prétraitement des Données

Afin de simplifier l'importation et la manipulation de cette base de données complexe, nous avons développé plusieurs fonctions dédiées :

Tout d'abord, des fonctions dédiées ont été créées pour **générer les chemins spécifiques aux différents fichiers associés à chaque patient**, en se basant sur leur **numéro**. Ces fonctions permettent de **localiser les fichiers d'IRM, les masques de segmentation** ou encore les fichiers informatifs au sein de la structure complexe de la base de données. Une fois ces chemins identifiés, **une fonction d'extraction des données intervient pour lire et récupérer** les informations nécessaires à partir des fichiers concernés.

En ce qui concerne les fichiers informatifs des patients, nous n'exécutons l'extraction que **des indices correspondant aux instants clés de la diastole et de la systole**. Les autres données incluses dans ces fichiers, comme le nombre total de frames, ont été soit déduites d'autres informations, soit considérées comme non pertinentes dans le cadre de notre étude.

Pour illustrer, nous avons extrait et visualisé un exemple de fichier informatif pour le premier patient du jeu d'entraînement, ainsi que les images IRM correspondantes.

```
ED: 1  
ES: 12  
Group: DCM  
Height: 160.0  
NbFrame: 30  
Weight: 70.0
```

Figure 2-1 Fichier info pour un patient exemple




Figure 2-2 Exemple de vérité terrain

3. Détection du Point Initial par la méthode de Hough cercle

3.1 Théorie

L'algorithme de Hough constitue une méthode puissante et éprouvée pour détecter les formes géométriques dans le cadre du traitement d'images. Cette technique repose principalement sur la transformation des informations de l'espace image en un espace paramétrique, permettant ainsi une identification efficace des formes telles que les lignes ou les cercles.

Dans notre cas, nous avons appliqué cet algorithme pour détecter les contours et cercles représentant le ventricule gauche à partir des images dans notre base de données.

3.1.1 Étapes Préliminaires : Détection des Contours

Avant de passer à la détection des cercles, il est crucial d'extraire les contours de l'image, une opération réalisée grâce à l'algorithme **Canny**. Nous avons utilisé la fonction pré-implémentée d'OpenCV, qui repose sur quatre étapes fondamentales :

- *Lissage de l'image* : L'image est lissée à l'aide d'un filtre gaussien caractérisé par une variance σ^2 . Ce lissage réduit le bruit dans l'image : $I_{\text{lissé}} = I * G_{\sigma}$
- *Calcul du gradient et de sa direction* : Le gradient $|G|$ et son orientation θ sont calculés à l'aide des filtres de Sobel, permettant une estimation rapide :
 - $|G| = \sqrt{G_x^2 + G_y^2}$, $\theta = \arctan\left(\frac{G_y}{G_x}\right)$
- *Suppression des non-maxima* : Seules les valeurs de gradient correspondant aux contours les plus nets sont retenues.
- *Double seuillage* : Un double seuillage permet d'identifier et de conserver uniquement les contours bien définis.

3.1.2 Détection des Cercles : Algorithme de Hough

Après avoir extrait les contours, l'étape suivante consiste à identifier les cercles à l'aide de la méthode de Hough pour cercles. Cette méthode fonctionne comme suit :

a) Transformation Paramétrique :

Chaque point de contour dans l'espace image est transformé en un ensemble de cercles possibles dans l'espace paramétrique (x_c, y_c, r) , où (x_c, y_c) représentent les coordonnées du centre, et r , le rayon.

Les centres potentiels sont calculés selon :

$$x_c = x - r \cdot \cos(\theta), \quad y_c = y - r \cdot \sin(\theta)$$

Pour $\theta \in [0, 2\pi]$. Le pas d'angle est un paramètre important dans l'algorithme.

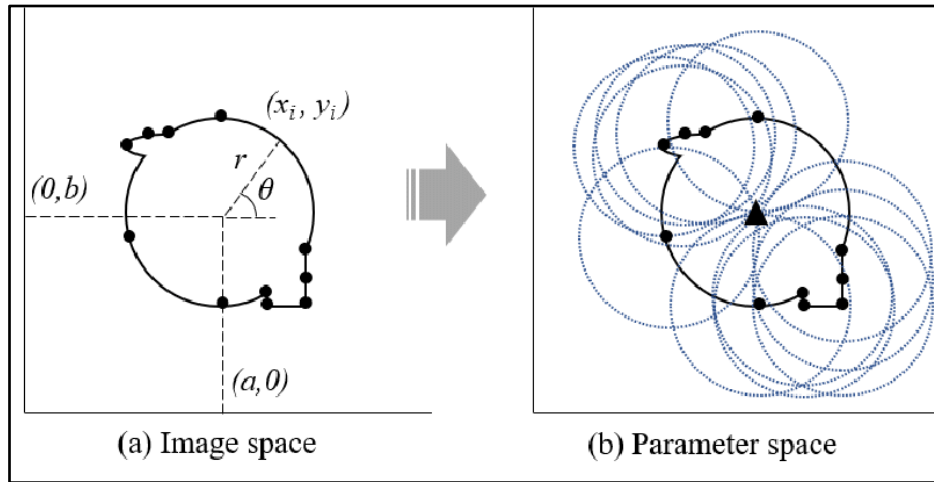


Figure 3-1 Transformation Paramétrique

b) Accumulation dans l'Espace Paramétrique :

Les centres possibles sont accumulés dans un espace 3D (x_c, y_c, r) . Les pics dans cet espace indiquent la présence potentielle d'un cercle. Ces pics sont validés en fonction d'un vote basé sur des rayons prédéfinis.

c) Fusion des Résultats :

Les centres proches ayant des rayons similaires sont fusionnés pour éviter les redondances.

3.1.3 Application au Ventricule Gauche

Les données étudiées comprennent une série d'images capturées dans le temps (dynamique cardiaque) et en hauteur (coupe). La question clé est de déterminer quelle image est la plus appropriée pour l'analyse des contours et la détection des cercles.

Deux approches sont explorées :

- *Méthode Basée sur la Différence Absolue :*

Le premier article [1] suggère d'utiliser la différence en valeur absolue entre les images correspondant aux instants de dilatation maximale (diastole) et de rétraction maximale (systole).

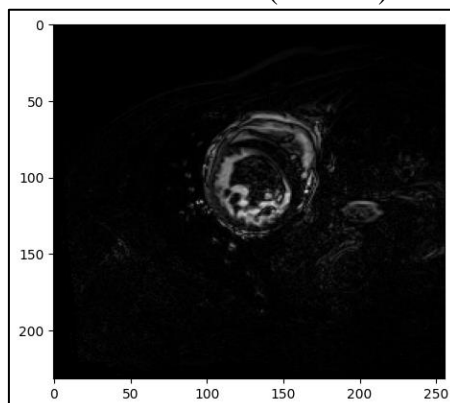


Figure 3-2 Photo de différence entre systole et diastole

- *Méthode Basée sur la Transformée de Fourier :*

Le second article [3] propose une approche basée sur la Transformée de Fourier pour éliminer la notion de temps. La première harmonique non nulle (harmonique fondamentale) est utilisée pour identifier les variations maximales entre les images.

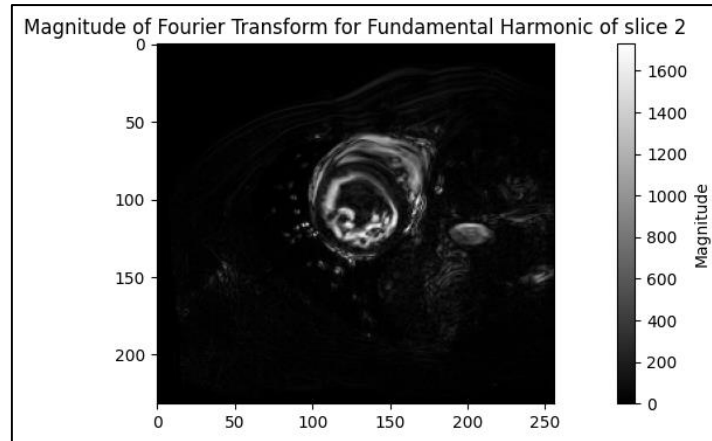


Figure 3-3 Photo de la première harmonique non nulle

➔ La méthode la plus adaptée sera déterminée expérimentalement.

L'application de l'algorithme de Hough pour la détection des cercles donne lieu à trois cas possibles :

- *Cas Optimal* : Un seul cercle est détecté, correspondant au ventricule gauche.
- *Cas Adéquat* : Plusieurs cercles sont détectés, mais le premier (avec le plus de votes) englobe le ventricule gauche.
- *Cas d'Échec* : Aucun cercle n'est détecté.

Ce développement méthodologique rigoureux garantit une meilleure identification du ventricule gauche, essentielle pour les analyses médicales ultérieures.

3.2 Implémentation

Comme on déjà discuter, Deux approches d'entrée ont été explorées pour fournir les données à l'algorithme : **la Méthode Basée sur la Différence Absolue** et **la Méthode Basée sur la Transformée de Fourier**, Ces approches permettent de préparer une image optimisée, où les contours pertinents du ventricule gauche sont mis en évidence.

Une fois les données préparé, deux variantes de l'algorithme de Hough ont été testées : une implémentation manuelle et une implémentation via la bibliothèque OpenCV.

3.2.1 Implémentation Manuelle de l'Algorithme de Hough

Dans cette méthode, nous avons implémenté l'algorithme de Hough de manière personnalisée **pour mieux comprendre son fonctionnement**.

Entrées du Code :

- Image originale : Image d'IRM de référence utilisée pour superposer les cercles détectés .
- Image des contours : Résultat de la détection des bords par l'algorithme de Canny sur différence ou fourrier, qui sert de base pour identifier les pixels susceptibles d'appartenir aux cercles.
- Intervalle des rayons (r_{mi}, r_{max}) : Définit la plage de rayons possibles pour les cercles à détecter, en fonction des dimensions estimées du ventricule gauche.
- Pas des rayons (Δr) : Résolution pour explorer les différentes tailles de cercles.
- Nombre d'angles (num_thetas) : Nombre de directions utilisées pour calculer les coordonnées des cercles dans l'espace paramétrique.
- Seuil du bin ($bin_threshold$) : Pourcentage minimal de votes nécessaires pour valider un cercle comme candidat.

3.2.2 Implémentation avec la Bibliothèque OpenCV

Pour comparer et valider les résultats de l'approche manuelle, nous avons également utilisé la fonction ``cv2.HoughCircles`` de la bibliothèque OpenCV, qui offre une implémentation optimisée de l'algorithme de Hough pour la détection de cercles.

Entrées du Code:

- Méthode : Nous avons utilisé `cv2.HOUGH_GRADIENT`, qui repose sur une approche de gradient pour identifier les cercles.
- dp : Ce paramètre détermine la résolution de l'accumulateur par rapport à l'image d'origine ; avec **dp = 1**, l'accumulateur conserve la même taille que l'image, garantissant une détection précise des cercles.

- minDist : Distance minimale entre les centres des cercles détectés, pour éviter les duplications.
- param1 : Ce paramètre contrôle le seuil supérieur utilisé dans l'algorithme de Canny pour **détecter les bords** dans l'image. Il détermine la sensibilité à la détection des contours : des valeurs plus élevées détectent des contours plus nets mais peuvent ignorer certains détails.
- param2 : Ce paramètre fixe le seuil minimal de **votes dans l'accumulateur pour qu'un cercle soit validé**. Une valeur plus élevée réduit les faux positifs en exigeant une correspondance plus stricte entre les votes des candidats et les cercles réels.
- minRadius et maxRadius : Plage des rayons à détecter, similaire à l'approche manuelle.

→ Il est clair que l'algorithme de détection des points initiaux (manuelle ou celui de opencv) repose sur **plusieurs paramètres critiques**, comme `param1` et `param2`, dont la sensibilité peut influencer directement les résultats. De plus, les deux approches testées – **la méthode basée sur la différence entre la diastole et la systole**, et celle utilisant **la transformée de Fourier** – présentent chacune des spécificités qui méritent une analyse approfondie. Par ailleurs, le **pré-traitement**, tel que l'égalisation d'histogramme, pourrait jouer un rôle clé en améliorant la clarté des images IRM, facilitant ainsi l'efficacité des algorithmes de Canny et de Hough.

Pour déterminer **les meilleures combinaisons possibles** de ces paramètres et optimiser l'ensemble du processus, nous introduisons dans la partie suivante un algorithme d'entraînement permettant de répondre à ces interrogations.

3.3 Entraînement, amélioration et recherche des paramètres optimaux

Dans cette section, notre objectif est de tester différentes combinaisons de paramètres pour identifier la configuration optimale permettant de maximiser la performance de l'algorithme de détection du point initial. Pour ce faire, nous avons défini **une fonction d'évaluation** qui mesure **le succès de l'algorithme**.

Elle vérifie, pour chaque patient du jeu d'entraînement, si le point initial détecté par l'algorithme de Hough **se trouve effectivement à l'intérieur du ventricule gauche** en se basant sur le masque de vérité terrain.

L'objectif est ainsi de déterminer **la meilleure méthode** – entre l'implémentation manuelle ou celle basée sur OpenCV – **combinée aux paramètres optimaux**.

Ces paramètres incluent notamment la méthode de **prétraitement** (différence entre diastole et systole ou harmonique fondamentale via la transformée de Fourier), ainsi que les paramètres spécifiques à chaque implémentation.

3.3.1 Approche adoptée pour l'optimisation

Etape 1 : Étude préliminaire des plages de paramètres :

Avant de procéder à un entraînement systématique, **des tests exploratoires** ont été réalisés pour étudier l'influence de chaque paramètre sur la détection du point initial. Cela a permis d'identifier les plages pertinentes de variation.

Par exemple, pour le paramètre ``bin_threshold`` dans l'implémentation manuelle, on a constaté que des valeurs trop faibles (<0.5) augmentent le risque de détecter des cercles incorrects, tandis que des valeurs trop élevées (>0.7) empêchent souvent de détecter correctement le ventricule gauche.

Des expériences similaires ont été menées pour chaque paramètre, comme les seuils d'intensité (``min_edge_threshold`` et ``max_edge_threshold``) ou le rayon maximal (``r_max``) pour l'algorithme manuel. **Cela a permis de restreindre les plages de recherche à des intervalles significatifs pour l'entraînement.**

Etape 2 : Impact du prétraitement (égalisation d'histogramme) :

Les images IRM étant souvent **sombres**, un prétraitement par **égalisation d'histogramme** a été envisagé pour **éclaircir les images** et rendre les contours du ventricule gauche plus distincts.

Etape 3 : Paramètres étudiés selon les méthodes :

- Pour OpenCV : ``param1``, ``param2``, Option d'égalisation d'histogramme, Sélection de la coupe optimale pour la détection du ventricule gauche.
- Pour l'implémentation manuelle : ``bin_threshold``, ``r_max``, ``min_edge_threshold`` et ``max_edge_threshold``, Option d'égalisation d'histogramme, Sélection de la coupe optimale pour la détection du ventricule gauche.

Remarque ‘Entraînements réalisés ‘ : Certains paramètres, comme la sélection de la coupe optimale et l’option d’égénération, **influencent de manière similaire** les deux méthodes. Afin de réduire le temps d’exécution, les résultats obtenus sur l’une des méthodes ont été directement utilisés pour l’autre.

D’ailleurs L’optimisation de chaque méthode sur un type d’image avec une large plage de paramètres exigeant de nombreuses heures d’exécution, nous n’avons entraîné que les modèles suivants :

- Implémentation manuelle de Hough sur l’harmonique fondamentale de Fourier.
- Implémentation OpenCV de Hough sur l’harmonique fondamentale de Fourier.
- Implémentation OpenCV de Hough sur la différence absolue entre diastole et systole.

Etape 4 : Validation

→ Pour chacun de ces cas, les paramètres optimaux obtenus à partir des exécutions sur le jeu d’entraînement ont ensuite été **validés sur le jeu de test**. Nous allons maintenant examiner les résultats et les analyser dans la section suivante.

3.4 Résultats et Discussion

3.4.1 Résultat

Dans cette section, nous présentons et analysons les résultats obtenus à partir des deux méthodes décrites précédemment : **l'approche basée sur l'harmonique fondamentale de la Transformée de Fourier** et **celle utilisant la différence absolue** entre les instants de diastole et de systole. Ces deux méthodes ont été appliquées sur les images du ventricule gauche pour évaluer leur efficacité dans la détection du centre.

Compte tenu du temps de calcul important nécessaire à l'entraînement des algorithmes sur les données, nous avons adopté une stratégie **d'enregistrement des paramètres optimaux dans des fichiers dédiés**. Une méthode spécifique a ensuite été développée pour extraire ces paramètres sous la forme d'un dictionnaire structuré, facilitant ainsi l'analyse des résultats. Pour chaque itération et amélioration des performances, nous avons consigné :

- Le nombre de patients pour lesquels le centre a été correctement détecté.
- Le dictionnaire des meilleurs paramètres locaux ayant conduit à ce résultat.

À la fin de chaque exécution, les derniers dictionnaires et compteurs sont extraits pour établir un bilan final des performances.

Pour évaluer l'efficacité des deux approches, nous avons calculé, pour chaque méthode et pour chaque image analysée, le pourcentage de patients dont le centre a été correctement détecté à l'intérieur du ventricule gauche, groupés dans le tableau suivant :

	Différence absolue		Harmonique fondamentale de Fourier	
	Train data	Test Data	Train data	Test data
Implémentation manuelle	25%	22%	48%	16%
Implémentation de OpenCV	82%	82%	91%	86%

a) Prétraitement : Harmonique fondamentale de Fourier vs Différence absolue ?

Les résultats montrent clairement que l'utilisation de **l'harmonique fondamentale de Fourier** comme prétraitement produit des performances supérieures, quel que soit l'algorithme utilisé (manuel ou OpenCV). Cela s'explique par le fait que l'harmonique fondamentale de Fourier **capture mieux les variations significatives** entre les coupes, indépendamment des fluctuations temporelles.

→ **Conclusion** : La différence absolue est abandonnée en tant que méthode de prétraitement au profit de l'harmonique fondamentale de Fourier.

b) Méthode : Implémentation OpenCV vs Implémentation Manuelle ?

L'implémentation **OpenCV** dépasse largement l'implémentation manuelle en termes de précision, aussi bien sur les données d'entraînement que de test.

→ **Conclusion** : L'implémentation **OpenCV** est adoptée pour la suite des travaux

c) Paramètres optimaux trouvés

Pour l'implémentation OpenCV utilisant l'harmonique fondamentale de Fourier, les paramètres optimaux obtenus après la phase d'entraînement sont :

- param1 : 170
- param2 : 30
- Coupe optimale (slice) : 1 (correspondant à la deuxième coupe spatialement)
- Égalisation d'histogramme : activée

3.4.2 Analyse des résultats et discussion

Les figures ci-dessous montrent des exemples où le point initial a été correctement détecté au sein de la **ventricule gauche (LV)** et dont le rayon approxime le rayon du **ventricule**. Ces résultats mettent en évidence la robustesse de l'algorithme, particulièrement dans des conditions favorables où les contours sont nets et bien définis




Figure 3-4 Illustration du succès de détection du point initiale

a) Discussion où la détection a échoué




Figure 3-5 Illustration d'échec pour patients 10, 11, 34, 47

- **Centres détectés en dehors de la LV :** *Patients 10, 11, 47* : Dans ces cas, l'algorithme a localisé le centre hors de la LV. Cela s'explique par le fait que la **ventricule droite (RV)**, combinée à la LV, forme une structure globalement circulaire. L'algorithme de Hough, privilégiant les formes circulaires, a donc attribué le centre à cette forme composite plutôt qu'à la seule LV.
- **Absence de données de validation :** *Patient 34* : Ici, bien que l'algorithme ait produit un résultat, celui-ci ne peut être qualifié de succès ou d'échec, car **aucune vérité terrain** n'est disponible pour ce patient. Cela limite l'interprétation des performances pour ce cas.




Figure 3-6 Illustration d'échec pour patients 6, 14, 33

- **Contours insuffisants ou inadéquats :** *Patients 6, 14, 33* : Dans ces cas, le centre n'a pas été détecté. Après analyse, on observe que :
 - Les **bords du LV sont trop fins ou insuffisamment marqués**, ce qui limite la détection de contours par l'algorithme de Canny.
 - Alternativement, des **contours trop larges (14)** ou irréguliers peuvent également induire une perte de précision dans la détection des cercles.

b) Discussion des optimisations (Choix de la coupe optimale)

Les premiers essais utilisaient **un indice fixe** (par exemple, la deuxième coupe) comme coupe optimale. Cependant, cette méthode peut se révéler un peu rigide, car le nombre **total de coupes varie significativement d'un patient à l'autre**.

→ **Amélioration proposée** : Sélectionner la coupe optimale en fonction d'un pourcentage de la taille totale des coupes.

→ **Résultat** : Après des tests, une coupe correspondant à **20% de la taille totale** a donné des résultats cohérents (**90% sur les données d'entraînement et 82% sur les données de test**). Toutefois, pour des raisons de **simplification** du code et de calculs, nous avons décidé de continuer à utiliser une coupe fixe (2^e spatialement) dans le reste du projet.

c) Pourquoi OpenCV surpasse-t-il l'implémentation manuelle ?

→ Efficacité algébrique grâce au gradient

L'un des atouts majeurs d'OpenCV réside dans l'utilisation **du gradient d'intensité** des pixels pour détecter les cercles :

- En analysant les variations locales de l'intensité lumineuse (direction et amplitude des gradients), OpenCV peut deviner les positions probables des centres de cercles.
- Ce suivi des gradients rend la méthode robuste et précise, car il permet de détecter non seulement les cercles évidents, mais aussi ceux dans des zones bruitées ou partiellement visibles.
- En combinant les informations du gradient avec un accumulateur pondéré (l'accumulateur attribue plus de poids aux votes provenant de pixels ayant des gradients cohérents), OpenCV réduit les faux positifs et améliore la localisation du centre.

3.5 Conclusion des résultats

→ L'implémentation OpenCV utilisant l'harmonique fondamentale de Fourier comme prétraitement avec égalisation est la meilleure combinaison testée, atteignant une précision de **91% sur les données d'entraînement et 86% sur les données de test**.

4. Segmentation du ventricule gauche par croissance de région

Dans cette section, nous abordons la segmentation du ventricule gauche (LV) à partir du point initial détecté précédemment. Cette tâche repose sur un algorithme de croissance de région (*region growing*) basé **sur un critère de similarité** contrôlé par **un seuil**. Le résultat final est un masque représentant le ventricule gauche segmenté.

4.1 Théorie (region growing)

L'algorithme de croissance de région fonctionne en explorant **les pixels voisins** d'un point initial donné, en vérifiant s'ils **satisfont un critère de similarité**. Si le critère est respecté, ces pixels sont ajoutés à la région segmentée. Ce processus est répété jusqu'à ce qu'aucun pixel supplémentaire ne puisse être intégré.

4.1.1 Étapes fondamentales :

1. *Initialisation*: Le processus démarre avec le point initial (x_0, y_0) .
2. *Vérification des voisins* : Chaque pixel voisin (x_i, y_i) est testé selon un critère de similarité : $\text{Critère}(I(x_i, y_i)) = \begin{cases} \text{Vrai si le pixel satisfait le seuil de similarité} \\ \text{Faux, si non} \end{cases}$
3. *Mise à jour de la région*: Si le critère est respecté, (x_i, y_i) est ajouté à la région segmentée R .
4. *Itération*: Le processus est répété pour tous les voisins du pixel nouvellement ajouté.

4.1.2 Critères de croissance de région :

Nous avons exploré deux critères principaux pour définir la similarité et contrôler la croissance de la région :

a) Intensité minimale

Dans cette approche, un pixel est ajouté à la région segmentée s'il a une intensité supérieure à un seuil $T_{min} : I(x, y) > T_{min}$

Cette méthode exploite la propriété que le ventricule gauche (LV) qui présente des intensités **plus claires** que les autres parties de l'image IRM.

b) Ressemblance avec le pixel initial

Ici, la similarité est définie **par la différence d'intensité** entre le pixel en cours d'examen et le pixel initial (x_0, y_0) :

Un pixel est intégré s'il ressemble suffisamment au pixel initial en termes d'intensité.

$$|I(x, y) - I(x_0, y_0)| \leq T_{diff}$$

4.1.3 Croissance avec seuils variables

Dans les deux approches décrites ci-dessus, il est difficile de fixer un **seuil unique** qui segmenterait parfaitement le ventricule gauche. Pour surmonter cette difficulté, nous adoptons une approche de seuils variables :

a) Pour l'intensité minimale

1. On commence avec un seuil T_{min} élevé pour ne prendre en compte que les pixels les plus clairs.
2. Progressivement, le seuil est **réduit** (pixels plus sombres inclus).
3. On observe l'évolution du volume segmenté : **une augmentation brusque** indique que la segmentation atteint des zones hors du LV (par exemple, le ventricule droit).
4. On identifie le **seuil juste avant cette discontinuité** et relance une segmentation finale avec ce seuil optimal.

b) Pour la ressemblance avec le pixel initial

1. Le seuil T_{diff} est progressivement augmenté, **élargissant la marge de similarité**.
2. Comme précédemment, une augmentation brusque du volume segmenté indique une segmentation incorrecte.
3. Le seuil optimal est identifié et utilisé pour une segmentation finale.

La discontinuité de volume est détectée grâce à un paramètre appelé volume ratio (VR), défini comme suit :

$$VR = \frac{V_{t+1}}{V_t}$$

où V_t représente le volume de la région segmentée à l'étape t , et V_{t+1} le volume à l'étape suivante. Lorsque ce ratio **dépasse** une valeur seuil prédéfinie (généralement entre 1,5 et 2), cela indique une **explosion de la région segmentée**.

Ce choix de seuil est justifié par le fait que lorsque la région segmentée s'échappe du ventricule gauche (LV), elle commence à inclure le **ventricule droit (RV)**. *Le volume du ventricule droit est généralement au minimum égal à la moitié de celui du ventricule gauche* [4]. Cette transition entraîne donc une augmentation significative et rapide du volume segmenté, détectée par le **ratio VR**.




Figure 4-1 Chemin de bloc de variation de seuil

4.2 Expérience et amélioration

4.2.1 Prétraitement

- Le processus de **region growing** dépend fortement des **intensités des pixels**, d'où la nécessité de normaliser toutes les images avant de définir précisément les seuils mentionnés précédemment. Une normalisation garantit une meilleure cohérence des seuils, quel que soit le patient.
- Par ailleurs, les images d'IRM présentent souvent des **bruits** et des **artéfacts sous forme de tâches sombres dans le ventricule gauche (LV)**. Ces imperfections risquent de bloquer la croissance de la région. Pour résoudre ce problème, un filtre médian d'un rayon optimal est appliqué pour lisser les zones tout en préservant les contours importants.
- Enfin, une égalisation d'histogramme est utilisée pour éclaircir les images, rendant les contours du LV plus visibles et facilitant ainsi la segmentation.

Illustrations :




Figure 4-2 avant et après application du filtre médian

On remarque ici que le bruit a été éliminer

4.2.2 Post-traitement

Une fois la région segmentée, des **artefacts IRM** sous forme de trous dans la région segmentée peuvent apparaître. Ces artefacts nécessitent l'utilisation d'outils morphologiques, en particulier l'opération de fermeture (*closing*), pour combler ces imperfections.

Le choix de l'élément structurant est crucial : nous utilisons un élément **structurant circulaire** pour s'adapter à la forme naturelle du LV. Cela permet de **combler les petits trous** tout en conservant la forme générale de la région segmentée.




Figure 4-3 avant et après Fermeture

On remarque ici que la fermeture a bien remplis les trous.

4.2.3 Définition des fonctions de croissance

a) Paramètres communs à toutes les deux approches :

- VR (Volume Ratio) : Un ratio de discontinuité typiquement fixé entre 1,5 et 2, utilisé pour détecter les expansions anormales.
- Rayon médian : Définit la taille du filtre médian appliqué pour réduire les bruits.
- Égalisation d'histogramme : Option permettant d'améliorer la visibilité des contours du LV.
- Morphologie : Utilisation d'une fermeture pour corriger les trous dans la segmentation.
- Indice de patient et la coupe sur laquelle on va commencer la segmentation n

b) Paramètres spécifiques à chaque méthode :

- Seuil d'intensité minimale : Seuil au-delà duquel les pixels sont inclus dans la région segmentée (généralement choisi comme l'intensité du point initial) .
- Tolérance initiale : Critère de ressemblance pour les pixels voisins, utilisé dans la méthode basée sur **la ressemblance avec le pixel initial**

4.2.4 Recherche des paramètres optimaux et entraînement

Pour obtenir une segmentation optimale, il est essentiel d'identifier les paramètres qui influencent le plus les résultats. La méthode suivie ici s'inspire des techniques d'optimisation déjà utilisées dans la section dédiée à la transformation de Hough.

a) Fonction coût à optimiser

Pour évaluer la qualité de la segmentation, nous utilisons l'**indice de Dice** (, qui mesure la similarité entre le masque segmenté et le masque de référence (vérité terrain)). Vue que nous avons calculer dans notre code le Jaccard La relation entre Dice et Jaccard est donnée par :

$$Dice = \frac{2|(A \cap B)|}{|A| + |B|} \text{ et } J = \frac{|(A \cap B)|}{|(A \cup B)|}$$

$$\rightarrow Dice = 2 * \frac{J}{1 + J}$$

→ L'objectif est de maximiser la moyenne de l'indice de Dice sur l'ensemble d'entraînement. Les paramètres optimaux ainsi obtenus sont ensuite validés sur l'ensemble de test.

b) Paramètres à optimiser

Pour chaque paramètre, nous effectuons **des ensemble d'exécution initiale** pour analyser leurs variations et déduire leurs plages de variation

Les principaux paramètres qui influencent la qualité de segmentation sont les suivants :

- Rayon du filtre médian [1...4]
 - **Un rayon trop grand** peut non seulement réduire le bruit, mais aussi supprimer les contours importants délimitant le LV, ce qui peut nuire à la segmentation.
 - **Un rayon trop petit**, en revanche, ne filtre pas suffisamment les bruits, ce qui peut entraîner des erreurs de croissance de la région.
- Rayon de l'élément structurant pour la fermeture [1...4]
 - Étant donné la forme circulaire du LV, le rayon de l'élément structurant utilisé dans l'opération de fermeture doit être adapté pour combler efficacement les trous sans altérer la forme globale de la région segmentée.
- Volume ratio VR
 - Bien que l'on sache que la discontinuité de volume se produit généralement pour un VR entre 1,5 et 2, il est important d'affiner cette plage pour obtenir des résultats précis. Un ajustement précis permet de détecter avec justesse le moment où la croissance échappe au LV pour entrer dans d'autres zones, comme le ventricule droit.
- Tolérance initiale (approche basée sur la ressemblance) [7...20]
 - Une tolérance trop faible risque d'arrêter la croissance avant que toute la région du LV ne soit segmentée.
 - Une tolérance trop élevée peut entraîner une sur-segmentation, incluant des zones qui ne font pas partie du LV.

c) Processus d'entraînement

1. Les paramètres initiaux sont testés sur l'ensemble d'entraînement en utilisant les points initiaux et les coupes détectées lors **des étapes précédentes**.
2. Pour chaque configuration de paramètres, l'indice de **Dice** est calculé pour évaluer la qualité de segmentation.
3. Les paramètres donnant le **Dice moyen maximal** sont sélectionnés comme **optimaux**.
4. Ces paramètres sont ensuite appliqués sur l'ensemble de test pour valider les performances du modèle.

→ Une fois les entraînements terminés, les résultats optimaux sont enregistrés pour une analyse approfondie. Les performances des différentes approches (basées sur l'intensité minimale et sur la ressemblance avec le pixel initial) sont comparées et discutées dans la section suivante.

4.3 Résultats et Discussion

4.3.1 Évaluation globale : Dice moyen

Les meilleurs résultats obtenus avec les paramètres optimaux pour chaque méthode sont récapitulés dans le tableau ci-dessous et validés sur le jeu de test :

Méthode	Dice moyen (Entraînement)	Dice moyen (Test)
Intensité minimale	0.756	0.75
Ressemblance au point initial	0.888	0.899

4.3.2 Impact des prétraitements et post-traitements

Pour mettre en évidence l'amélioration apportée par le **prétraitement** (filtre médian et égalisation d'histogramme) et le **post-traitement** (fermeture morphologique), nous avons comparé le Dice moyen sur le jeu de test dans différentes configurations :

Traitement appliqué	Dice moyen
Sans prétraitement ni post-traitement	0.811
Avec prétraitement et posttraitement(fermeture morphologique)	0.899

4.3.3 Illustration des résultats optimaux

Une série d'exemples visuels montrant les résultats de la segmentation optimale est présentée, mettant en avant le succès de segmentation

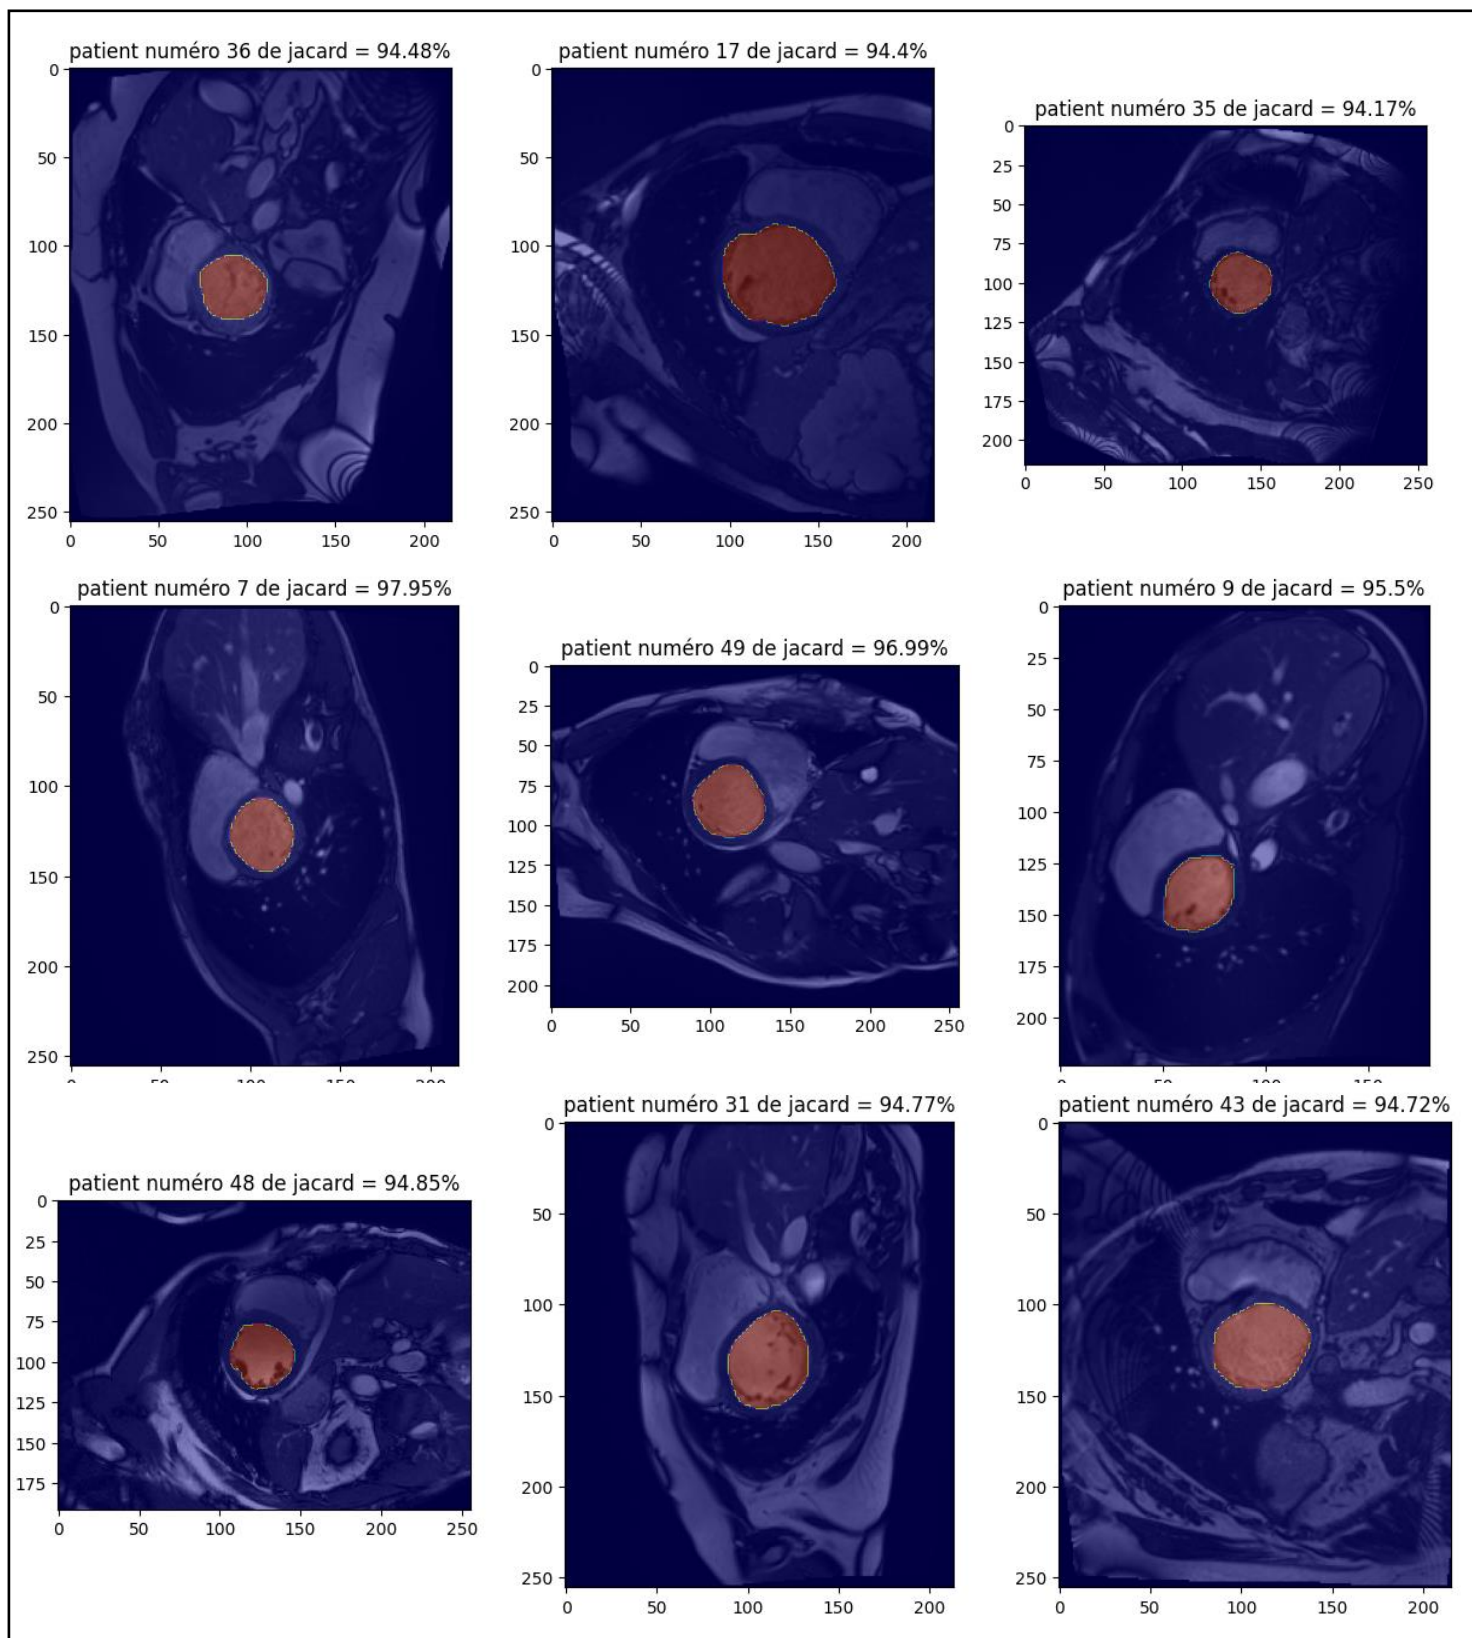


Figure 4-4 Visualisation du succès de la premier segmentation

4.3.4 Discussion des cas particuliers

Certains cas d'échec ou de sur-segmentation ont été observés :

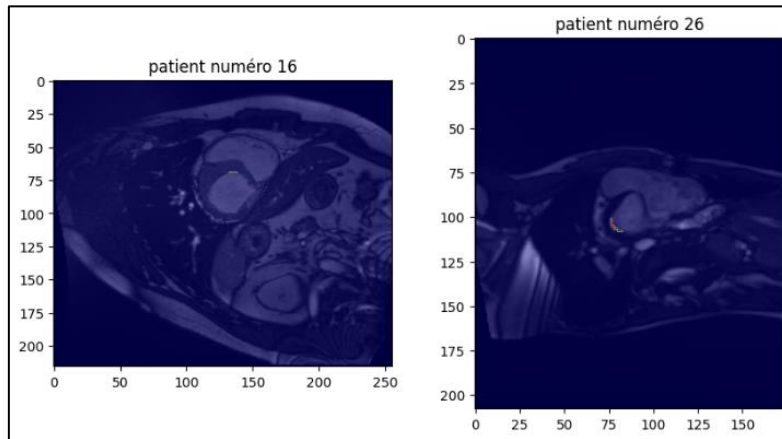


Figure 4-5 Mauvaise segmentation pour le patient 16 et 26

a) Cas d'échec de segmentation (patients 16 et 26) :

- La segmentation est incorrecte car le **point initial** se trouve bloqué dans une zone sombre proche du myocarde. Cela est dû à une mauvaise localisation initiale par la détection Hough. Ces cas ressemblent à ceux où la détection Hough échoue complètement.

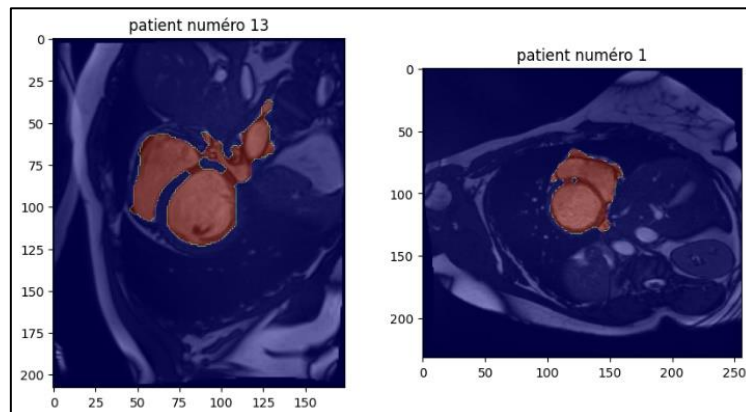


Figure 4-6 Sursugmentation pour patient 13 et e1

b) Cas de sur-segmentation (patients 13 et 1) :

- La segmentation envahit la région du **ventricule droit**, indiquant que la croissance de région dépasse les limites attendues.
- Cela peut être lié à des **paramètres de tolérance ou de volume ratio inadéquats** mais on ne peut pas les changer car ils on donne des résultats pertinents pour les autre patient.

4.4 Conclusion

→ Nous avons décidé de poursuivre avec la **méthode de ressemblance au point initial**, car elle offre les meilleurs résultats.

La segmentation finale inclut :

- Un **prétraitement** avec :
 - **Égalisation d'histogramme** pour éclaircir les images IRM.
 - **Filtre médian** (rayon optimal : 4) pour réduire le bruit.
 - **Normalisation**
- Un **post-traitement** avec :
 - **Fermeture morphologique** (élément structurant circulaire de rayon 2) pour corriger les artefacts.

→ Les paramètres optimaux trouvés sont :

- VolumeRatio=**1.6**,
- MedianRadius=**4**,
- Equalization=**True**,
- MorphoRadius=**2**,
- InitialTolerance=**7**

5. Propagation Spatio-Temporelle

Après avoir effectué toutes les étapes précédentes sur une coupe spécifique (typiquement celle où le **ventricule gauche est le plus visible**, souvent au moment de la **diastole**), il est nécessaire de généraliser les résultats à d'autres coupes cardiaques (**propagation spatiale**) et à d'autres instants temporels comme la systole (**propagation temporelle**).

Cette section s'intéresse à la manipulation des images IRM cardiaques en 3D et en 4D (**3D + temps**). Nous nous inspirons de l'article [1] et adoptons une méthode de propagation basée sur la **minimisation d'énergie**.

5.1 Théorie

Pour propager le point initial et la segmentation à travers les autres coupes et phases, une technique **de propagation basée sur un critère d'énergie** est utilisée. Cette approche permet de définir le point de départ (seed point) pour chaque nouvelle image en se basant sur les informations de **l'image précédemment traitée**.

5.1.1 Formulation de l'Énergie

Pour chaque image cible (qu'elle soit spatiale ou temporelle), une fenêtre carrée de 11×11 pixels est centrée sur le centre de gravité P_{CoG} de la région segmentée du ventricule gauche dans l'image précédente. L'énergie de chaque pixel p dans cette fenêtre est calculée selon l'équation suivante :

$$E(p) = \sqrt{\left(\frac{2\sigma_{prev}}{w-1} |P_{CoG} - p|\right)^2 + (I_{new}(p) - \mu_{prev})^2}$$

Avec les notations suivantes :

- p : position du pixel évalué.
- $I_{new}(p)$: intensité du pixel évalué dans l'image cible.
- P_{CoG} : centre de gravité de la région segmentée dans l'image précédente.
- σ_{prev} et μ_{prev} : écart-type et moyenne des intensités de la région segmentée dans l'image précédente.
- w : largeur de la fenêtre (ici, $w=11$).

a) Premier terme : $\left(\frac{2\sigma_{prev}}{w-1} |P_{CoG} - p|\right)^2$:

- Pénalise les pixels **éloignés du centre de gravité** précédent.
- Garantit que le seed point reste proche de la région précédemment segmentée.

b) Deuxième terme : $(I_{new}(p) - \mu_{prev})^2$:

- Pénalise les **pixels dont l'intensité diffère significativement** de la moyenne de l'intensité sanguine μ_{prev} observée dans l'image précédente.
- Assure une cohérence des intensités dans la propagation.

→ **Minimisation d'Énergie** : Le critère d'énergie garantit que le point propagé reste dans la région du ventricule gauche en respectant à la fois la proximité spatiale et la cohérence des intensités.

5.2 Implémentation (Propagation spatiale) :

L'implémentation de la propagation spatio-temporelle est organisée en deux fonctions principales : *seed_propagation* et *propagate seeds and masks Flood test prop*, qui travaillent en tandem pour propager les points de départ (seeds) et les masques segmentés à travers les différentes **coupes** et phases temporelles des IRM cardiaques.

Contexte : Pour l'instant, nous testons uniquement la **propagation spatiale** (entre coupes) car nous ne disposons pas de **vérités terrain** pour d'autres instants (sauf pour systole et diastole).

5.2.1 Fonction *seed_propagation*

Identifier le meilleur point de départ (**seed point**) dans une nouvelle coupe en minimisant une fonction d'énergie. Le pixel avec la plus faible énergie est choisi comme nouveau seed point.

5.2.2 Fonction *propagate seeds and masks Flood test prop*

Étendre la segmentation d'une coupe de référence à d'autres coupes (avant et après).

Étapes :

a) Initialisation :

- Les dictionnaires *all_seeds*, *all_masks*, et *all_prevs* sont créés pour stocker les points de départ, les masques segmentés, et les caractéristiques statistiques (moyenne et écart-type des intensités) pour chaque coupe.

b) Traitement de la Coupe Initiale :

- La segmentation initiale est réalisée sur une coupe ou phase donnée, identifiée par *best_slice* (provenant de l'étape 1 de notre pipeline).
- Cette segmentation sert de point de départ pour propager les informations.

c) *Propagation Spatiale* :

- **Vers les coupes précédentes** (en remontant de `best_slice - 1` à 0) : La fonction `seed_propagation` détermine le seed point pour chaque coupe. La segmentation est effectuée via `region_growing_mask_Flood_test` défini précédemment, en utilisant les seeds propagés.
- **Vers les coupes suivantes** (de `best_slice + 1` à la dernière coupe) : Même logique que pour les coupes précédentes.

d) *Gestion des Pixels Invalides* :

- Si aucune segmentation initiale n'est disponible, une matrice de zéros est assignée comme masque par défaut.

5.3 Résultats de la Propagation Spatiale

Dans cette section, nous évaluons la performance de la **propagation spatiale** en utilisant une métrique adaptée à l'analyse volumique : le **Dice 3D**, qui évalue la qualité de la segmentation sur l'ensemble des coupes d'une séquence IRM.

5.3.1 Évaluation initiale : Dice 3D moyen

Le Dice 3D a été calculé sur les **50 patients du jeu de test**. Les résultats sont les suivants :

Métrique	Test (50 patients)
Dice 3D moyen	0.75

Ce score met en évidence des limitations dans certains cas. Pour mieux comprendre, nous avons visualisé les résultats des segmentations.

Ici le masque rouge représente **notre segmentation** le masque vert **la vérité terrain** et le jaune **l'intersection** :

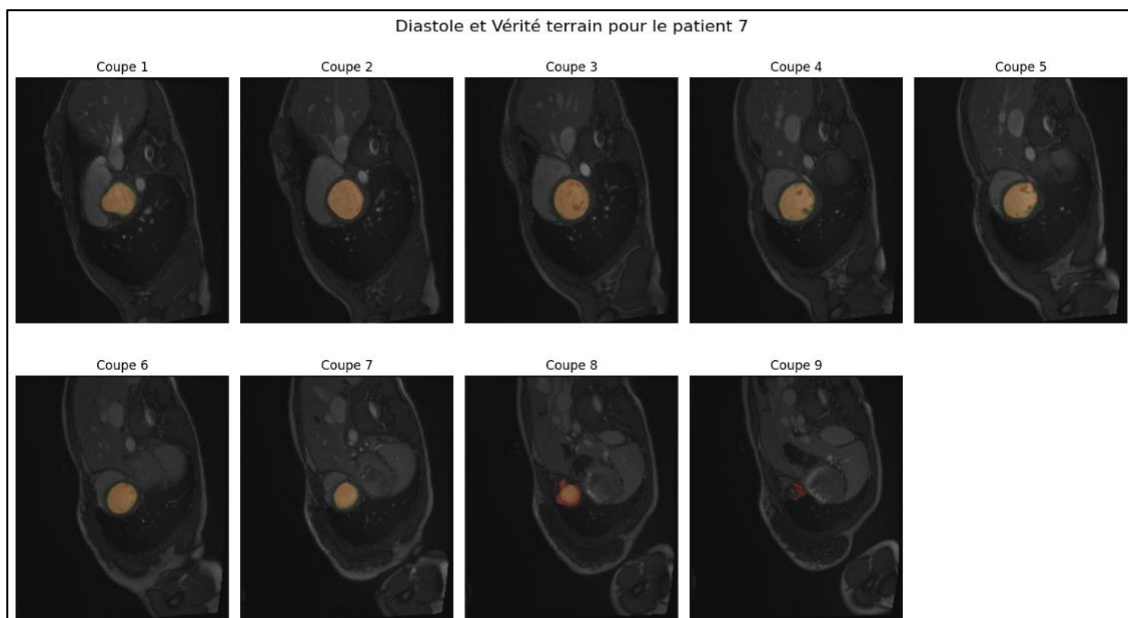


Figure 5-1 Propagation de la segmentation pour le patient 7

Diastole et Vérité terrain pour le patient 49




Figure 5-3 Propagation de la segmentation pour le patient 49

Diastole et Vérité terrain pour le patient 9




Figure 5-2 Propagation de la segmentation pour le patient 9

5.3.2 Analyse des résultats

a) **Observation principale** : Dans de nombreux cas, les dernières coupes présentent une **segmentation incorrecte**.

- Le **ventricule gauche** est souvent très petit dans ces coupes finales, ce qui complique la localisation et la propagation du point initial.
- Cela peut entraîner une **évasion du point initial** en dehors de la région à segmenter, diminuant ainsi la précision de la segmentation.

b) **Hypothèse testée** : Pour vérifier cette observation, nous avons recalculé le Dice 3D après avoir **éliminé le dernier sixième des coupes** (où la segmentation est la plus susceptible d'échouer).

c) **Résultats après ajustement** : En éliminant les coupes problématiques, le Dice 3D moyen a considérablement augmenté :

Métrique	Test (50 patients)
Dice 3D moyen (ajusté)	0.81

Cette augmentation confirme notre hypothèse selon laquelle les coupes finales sont la principale cause de la diminution du Dice moyen initial.

5.3.3 Interprétation des résultats

a) **Problème identifié** : La propagation spatiale est sensible aux variations anatomiques dans les coupes où le ventricule gauche est très réduit. Cela suggère une **faiblesse dans la robustesse de l'approche pour les petites régions**.

b) **Correction potentielle** : Pour améliorer la performance globale :

- Inclure des mécanismes pour éviter que le **point initial ne s'échappe** (par exemple, en limitant la propagation aux zones proches de la segmentation précédente).

5.4 Propagation Temporelle

Après avoir testé la propagation spatiale, nous avons appliqué un **principe similaire** pour réaliser la propagation temporelle. Cette approche vise à segmenter les autres phases cardiaques (par exemple, la systole), en se basant sur la segmentation initiale obtenue à la diastole.

La méthode suit les étapes suivantes :

a) Point de départ :

- La segmentation obtenue à la diastole (phase où le ventricule gauche est le plus visible) est utilisée comme point de référence.
- Le point initial est propagé en exploitant les relations entre les phases temporelles successives.

b) Critère de propagation :

- Les paramètres énergétiques similaires à ceux définis pour la propagation spatiale sont adaptés pour prendre en compte les variations temporelles.
- Ces variations incluent la contraction et la dilatation du ventricule gauche entre la diastole et la systole.

c) Limites actuelles :

Malheureusement, nous ne disposons pas des **vérités terrain** (segmentations manuelles) pour les phases temporelles autres que la diastole et la systole. Par conséquent, il est impossible d'évaluer quantitativement la propagation temporelle via des métriques comme le Dice.

Pour compenser l'absence de données d'évaluation, nous avons essayé de propager seulement de la diastole au systole par deux méthodes récapitulé dans le tableau ci-dessus et voici le dice 3d moyenne pour tous les patients de test sur la systole.

Dice3D si on prend le premier centre et on le propage spatialement sur l'instant du Sys	0.5
Dice3D si on prend le point initial de la segmentation celui du centre de LV en DES	0.53

Il est évident que le point initial a une influence significative sur les résultats de segmentation pour le cas de la systole. Par conséquent, il est essentiel de propager ce point correctement, c'est-à-dire de frame en frame, jusqu'à atteindre la systole. Nous illustrons cette propagation dans la figure suivante.

Malheureusement, cette propagation temporelle **est très coûteuse en termes de temps d'exécution**. Ainsi, nous avons pu l'exécuter uniquement pour un seul patient. Pour ce patient, nous avons calculé le Dice 3D de la systole, qui a montré une amélioration notable, atteignant une valeur de 0,74.

De plus, nous observons que, pour ce patient, le frame correspondant à la systole a été correctement segmentée (**rectangle rouge**). Cependant, nous notons également que, dans la dernière coupe, le ventricule gauche (LV) est peu visible. Cela explique pourquoi il n'a pas été possible d'effectuer une segmentation précise (**indiquée par le cercle jaune sur l'image**).

En outre, nous remarquons une **surgmentation** (**indiquée par le cercle vert**) due au mélange du LV avec d'autres structures anatomiques dans cette coupe, probablement à cause des limitations inhérentes à l'imagerie IRM.




Figure 5-4 Propagation spatio-temporelle

6. Vers une Ouverture : Approches Basées sur le Deep Learning

Dans ce projet, nous avons développé une méthode **semi-automatique** pour segmenter le ventricule gauche en trois étapes principales : détection du point initial, segmentation de région et propagation spatiale et temporelle. Bien que les résultats soient globalement satisfaisants, certaines limitations, comme **la sensibilité aux paramètres et les difficultés dans les zones de faible contraste**, montrent que des approches plus automatisées et robustes pourraient améliorer les performances. Cela nous amène à envisager des solutions plus modernes comme celles basées sur le **deep learning**.

Le **deep learning**, ou apprentissage profond, est une branche de l'intelligence artificielle qui utilise des réseaux de neurones pour traiter des données complexes. Ces réseaux apprennent directement à partir des données, sans nécessiter de règles explicites comme dans les méthodes traditionnelles. Cela pourrait offrir une solution plus automatisée et plus robuste à la segmentation du ventricule gauche.

6.1 Une découverte basée sur la recherche

Après avoir exploré les travaux existants, nous avons identifié plusieurs articles qui montrent comment le deep learning est utilisé pour ce type de tâche. Voici quelques méthodes clés :

6.1.1 U-Net : Segmentation efficace et populaire

Le U-Net [5] est un réseau de neurones conçu spécifiquement pour les tâches de segmentation en imagerie biomédicale. Il fonctionne en deux étapes principales : **une phase de contraction** qui extrait les caractéristiques importantes à partir de l'image, suivie d'une phase **d'expansion** qui reconstruit une image segmentée en haute résolution. Grâce à ses connexions de type *skip*, le U-Net préserve les détails fins tout en segmentant des structures complexes comme le ventricule gauche.

6.1.2 nnU-Net : Standardisation des tâches de segmentation médicale

Le **nnU-Net** [6] est une version améliorée et généralisée du U-Net. Il est conçu pour s'adapter automatiquement à tout type de données médicales sans besoin de réglages manuels complexes. Ce framework ajuste ses paramètres en fonction des caractéristiques des données, rendant son utilisation simple et efficace pour diverses applications, y compris la segmentation cardiaque.

6.1.3 Attention U-Net : Améliorer les performances avec des mécanismes d'attention

Cette variante du U-Net [7] intègre des mécanismes d'attention pour améliorer les performances de segmentation. Ces mécanismes permettent au modèle de se concentrer sur les régions d'intérêt les plus pertinentes dans une image, tout en ignorant les zones moins importantes. Cela est particulièrement utile pour les images médicales complexes, où les régions cibles peuvent être difficiles à distinguer.

Conclusion

En conclusion, ce travail a permis d'explorer et de mettre en œuvre une chaîne complète allant de la détection du point initial à la segmentation et à la propagation spatio-temporelle des images IRM cardiaques. Bien que notre méthode ait montré des performances prometteuses, certaines limitations subsistent, notamment dans les cas où la propagation spatiale échoue en raison de la petite taille des coupes terminales ou d'un mauvais positionnement initial.

Par ailleurs, l'ouverture vers des approches basées sur le deep learning, comme les réseaux U-Net et leurs variantes, offre des perspectives intéressantes pour améliorer davantage la segmentation. Ces techniques modernes permettent une plus grande précision et une automatisation accrue, ce qui pourrait s'avérer très bénéfique pour des tâches similaires.

Enfin, nous serions très ravis et excités de tester ces méthodes dans d'autres modules de la filière IMA au fur et à mesure que nous avançons dans nos cours, afin d'approfondir notre compréhension et d'explorer de nouvelles applications dans ce domaine fascinant. Elles représentent une ouverture naturelle pour améliorer notre méthode actuelle et mieux répondre aux défis de segmentation dans les IRM cardiaques.

Références

[1] Article 1: <https://ieeexplore.ieee.org/abstract/document/4776520>

[2] Data: <https://ieeexplore.ieee.org/abstract/document/4776520>

[3] Article 2: hened, Mahendra, Varghese Alex Kollerathu, and Ganapathy Krishnamurthi. "Fully convolutional multi-scale residual DenseNets for cardiac segmentation and automated cardiac diagnosis using ensemble of classifiers." *Medical image analysis* 51 (2019): 21-45. [Annexe B uniquement.] <https://www.sciencedirect.com/science/article/pii/S136184151830848X#sec0048>

[4] On a posé une question à une étudiante en 3e année de médecine, Mme Fatnassi Nermine, qui nous a confirmé la plage à laquelle le ratio de volume entre le ventricule droit et le ventricule gauche appartient.

[5] **Article** : Ronneberger et al., 2015 – "*U-Net: Convolutional Networks for Biomedical Image Segmentation*" <https://arxiv.org/abs/1505.04597>

[6] **Article** : Isensee et al., 2021 – "*nnU-Net: a self-adapting framework for U-Net-based medical image segmentation*" <https://pubmed.ncbi.nlm.nih.gov/33576729/>

[7] **Article** : Oktay et al., 2018 – "*Attention U-Net: Learning Where to Look for the Pancreas*" <https://arxiv.org/abs/1804.03999>